

Optimisation bayésienne multiobjectif avec un nombre limité d'évaluations

Laboratoire : Laboratoire des Signaux et Systèmes (L2S, UMR 8506), CNRS, CentraleSupélec, Université Paris-Saclay.

Adresse : bâtiment Bréguet, 3 rue Joliot-Curie, 91190 Gif-sur-Yvette.

Encadrant : Emmanuel Vazquez, emmanuel.vazquez@centralesupelec.fr.

1. Contexte et orientation du projet

Ce projet associe mathématiques, statistique, machine learning et IA autour de l'optimisation multiobjectif. On cherche à choisir les paramètres d'un système physique ou d'un algorithme, les *variables de décision*, pour améliorer plusieurs grandeurs à minimiser ou à maximiser, les *objectifs*. Par exemple, on peut choisir l'architecture d'un réseau de deep learning pour maximiser la précision des prédictions et minimiser le temps de calcul. Ces objectifs peuvent s'opposer. On recherche les solutions dont aucun objectif ne peut être amélioré sans en dégrader un autre. Les valeurs correspondantes des objectifs forment le *front de Pareto*.

Une *évaluation* fournit les valeurs des objectifs pour un choix des variables, appelé *point d'évaluation*. Elle peut nécessiter une simulation ou un entraînement coûteux, ce qui limite le nombre de points évaluable. Des modèles probabilistes, ici des processus gaussiens, décrivent à partir des évaluations passées comment les objectifs dépendent des variables. En *optimisation bayésienne*, un algorithme exploite les prédictions des modèles et les incertitudes associées au moyen d'un *critère d'échantillonnage* pour choisir le prochain point à évaluer. Les modèles sont ensuite mis à jour avec les nouvelles valeurs obtenues.

Questions de recherche. Comment répartir un budget limité d'évaluations pour approcher le front de Pareto ? Quelles garanties peut-on établir sur la qualité de cette approximation ? Le projet s'appuiera sur l'étude des méthodes existantes, de leurs hypothèses et de leurs limites pour situer les contributions proposées dans la littérature. Il visera à **concevoir de nouveaux algorithmes et critères d'échantillonnage** et à **étudier leurs performances théoriques et numériques**. L'analyse portera sur la convergence, l'erreur d'approximation du front et le coût de calcul en fonction du budget, sous des hypothèses explicites.

L'étude portera particulièrement sur les approches **SUR** (*Stepwise Uncertainty Reduction*, réduction séquentielle de l'incertitude) [6, 7]. En optimisation multiobjectif [8], elles reposent sur une mesure de l'incertitude sur le front de Pareto ou l'ensemble des solutions optimales et choisissent le prochain point d'évaluation pour minimiser l'incertitude résiduelle espérée, compte tenu des évaluations déjà disponibles. Le choix de cette mesure et le calcul du critère associé feront partie des questions étudiées.

Les méthodes de comparaison comprendront l'amélioration espérée de l'hypervolume et les scalarisations aléatoires. L'*hypervolume* mesure, dans l'espace des objectifs, le volume de la région dominée par les vecteurs d'objectifs déjà observés et bornée par un point de référence choisi moins favorable sur chaque objectif.

Cadre de travail. L'étude s'inscrit dans les recherches du L2S en optimisation bayésienne. Les expériences porteront sur des fonctions tests.

2. Résultats attendus et livrables

Les livrables comprendront un rapport scientifique et le code Python des méthodes et des expériences. Les résultats seront présentés lors d'une soutenance finale. Des contributions au package GPmp [9] ou à son extension `gmp-contrib` pourront être proposées.

3. Compétences à l'œuvre et approches

Compétences mobilisées. Probabilités, statistique, optimisation, algèbre linéaire et Python. Les processus gaussiens, la dominance de Pareto et la planification séquentielle d'expériences seront approfondis au fil du projet, en associant bibliographie, formalisation, expérimentation et rédaction.

Démarche méthodologique, théorique et expérimentale.

- Étudier les méthodes existantes, notamment les approches SUR, leurs mesures d'incertitude et leurs critères d'échantillonnage. Sélectionner des méthodes de référence et les mettre en œuvre à l'aide de bibliothèques existantes. Identifier leurs limites et les questions laissées ouvertes.
- Concevoir de nouveaux algorithmes et critères d'échantillonnage. Les situer par rapport aux travaux existants et les étudier sur les plans théorique et expérimental.
- Étudier les garanties connues et analyser les performances théoriques des algorithmes proposés. Préciser les hypothèses sur les fonctions, les modèles et la sélection des points. Rechercher des garanties de convergence ou des bornes sur l'erreur d'approximation du front en fonction du budget.
- Comparer les méthodes à budgets identiques, avec les mêmes points initiaux par répétition et des règles communes de modélisation. Fixer la normalisation et le point de référence de l'hypervolume. Inclure une référence non adaptative et répéter les expériences pour analyser la variabilité des résultats.
- Mesurer séparément qualité des compromis et coûts des évaluations, du modèle et de la sélection des points. Confronter théorie et expériences sur les fonctions tests, en précisant les limites de généralisation.

Encadrement proposé. L'encadrement reposera sur une réunion scientifique hebdomadaire et un suivi régulier des développements logiciels.

4. Planning prévisionnel

Le calendrier sera adapté à l'organisation des projets de la mention ICE.

- Bibliographie, formulation du problème, méthodes de référence et premiers tests.
- Conception d'algorithmes, analyses théoriques et expériences comparatives.
- Approfondissement théorique et confrontation aux résultats numériques, finalisation du rapport et du code, soutenance.

5. Bibliographie indicative

1. M. T. M. Emmerich et A. H. Deutz (2018). *A tutorial on multiobjective optimization : fundamentals and evolutionary methods*. Natural Computing, 17, 585–609. Article.
2. M. T. M. Emmerich, A. H. Deutz et J. W. Klinkenberg (2011). *Hypervolume-based expected improvement : Monotonicity properties and exact computation*. IEEE CEC, 2147–2154. Article.
3. P. Feliot, J. Bect et E. Vazquez (2017). *A Bayesian approach to constrained single- and multi-objective optimization*. Journal of Global Optimization, 67, 97–133. Version en accès libre.
4. B. Paria, K. Kandasamy et B. Póczos (2020). *A Flexible Framework for Multi-Objective Bayesian Optimization using Random Scalarizations*. PMLR, 115, 766–776. Article.
5. M. Zuluaga, G. Sergeant, A. Krause et M. Püschel (2013). *Active Learning for Multi-Objective Optimization*. PMLR, 28(1), 462–470. Article (identification du front et garanties sur un ensemble fini).
6. J. Villemonteix, E. Vazquez et E. Walter (2009). *An informational approach to the global optimization of expensive-to-evaluate functions*. Journal of Global Optimization, 44(4), 509–534. Version en accès libre (IAGO).
7. J. Bect, D. Ginsbourger, L. Li, V. Picheny et E. Vazquez (2012). *Sequential design of computer experiments for the estimation of a probability of failure*. Statistics and Computing, 22(3), 773–793. Version en accès libre.
8. V. Picheny (2015). *Multiobjective optimization using Gaussian process emulators via stepwise uncertainty reduction*. Statistics and Computing, 25, 1265–1280. Version en accès libre.
9. E. Vazquez (2026). *GPmp : Gaussian Process micro package*. <https://github.com/gpmp-dev/gpmp>.